

Теоретические основы информатики

Разделы	Темы
Информация и данные	Основные понятия информатики Кодирование информации
Двоичная математика	Системы счисления Битовые операции
Модели и структуры данных	Типы данных Структуры данных
Хранение и обработка данных	Структурированные файлы Парсинг данных Регулярные выражения
Методы информатики	Алгоритмизация Сортировка

Беляков Андрей Юрьевич

к.т.н., доцент

Тема 7

gitverse.ru/band/TOI

Раздел 4. Хранение и обработка данных

Тема 7

Плоские и иерархические данные

- Структурированные файлы форматов json, csv, yaml, xml.
- Библиотеки и методы работы со структурированными данными.

Тема 8

Парсинг данных

- Автоматизация сбора, фильтрации и агрегации данных.
- Автоматизация обработки данных (запись, чтение, библиотеки).

Тема 9

Регулярные выражения

- Понятие, области применения, синтаксис.
- Практические примеры поиска и замены в строках.

Тема 7

Плоские и иерархические данные

Вопрос 1: Плоские данные

txt, csv

Вопрос 2: Иерархические данные

json, yaml, xml

Тема 7

Плоские и иерархические данные

рассмотреть и обсудить примеры файлов
txt, csv, json, yaml, xml
и короткие программы доступа к данным

	data		<Папка..
	01-txt	py	75
	02-csv	py	278
	03-json	py	151
	04-yaml	py	269
	05-xml	py	229

Имя	Тип	Размер
	Имя	
	..	<Папка..
	103	yaml 1,2 K
	customers	xml 15,1 K
	exam_balls	csv 1,7 K
	lang_rate	txt 287
	users	json 5,7 K

Вопрос 1

Плоские данные

Flat Data



- данные представлены в виде списка записей, то есть в виде обычных таблиц - Excel
- каждая запись - это один объект
- запись представлена коллекцией значений
- каждый элемент коллекции - это значение свойства объекта
- все записи имеют одинаковую структуры
- то есть "поле n" во всех записях - имеет один и тот же смысл
- некоторые поля могут быть пустыми

Плоские данные

Calibri 11 A A Вставить Буфер обм... Шрифт Выравнивание Общий Число Условное форматирование Стили Вставить Ячейки Сортировка и фильтр Найти и выделить Редактирование																	
A1																	
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
5																	
6				Группа товара (ЛС 1 или П/Ф 2)	Государственная регистрация		Отпускная цена производителя (без НДС)	Отпускная надбавка оптового		Отпускная цена оптового предприятия	Розничная надбавка аптечного		Отпускная цена аптечного предприятия (без НДС)	НДС		Розничная цена аптечного предприятия с НДС	
7	№	Наименование	Серия		Дата	Рег. номер					%	Сумма		%	Сумма		
8																	
9	1	Эзомепразол, таблетки покрытые оболочкой	260713	1	12.09.2010	658575389	490,00р.	13,00%	63,7	553,7	30%	147	700,7	0,1	70,07	770,77	
10	2	Тиоктовая кислота, капсулы	7370220	1	05.01.2012	87838376894	970,00р.	11,00%	106,7	1 076,70р.	23,4%	227	1303,68	0,1	130,37р.	1 434,05р.	
11	3	Смесь НАН-З	78674578	2	06.05.2012	85737865	68,00р.	13,00%	8,84	76,84р.	30%	20,4	97,24	0,18	17,50р.	114,74р.	
12	4	Актовегин, ампулы	540913	1	04.09.2011	124343213	55,00р.	13,00%	7,15	62,15р.	30%	16,5	78,65	0,1	7,87р.	86,52р.	
13	5	Витамин А, капсулы	768413	1	04.08.2009	576567756	14,00р.	15,00%	2,1	16,10р.	32%	4,48	20,58	0,1	2,06р.	22,64р.	
14	6	Флемоксин солютаб, таблетки	5670913	1	16.07.2011	896794867	31,05р.	15,00%	4,6575	35,71р.	32%	9,936	45,6435	0,1	4,56р.	50,21р.	
15	7	Кагоцел, таблетки	7861013	1	25.05.2011	4896749	200,00р.	13,00%	26	226,00р.	30%	60	286	0,1	28,60р.	314,60р.	
16	8	Соска															
Ценообразование расчеты																	
Ценообразование изм. параметров																	

можно
сохранить
в csv

можно
сохранить
в таблицу
БД

одна запись

Плоские данные

CSV

```
id,lastName,rating,gender,birthDate,city
```

```
1,Мишкин,217,1,2002-08-23,Кунгур
2,Бортич,224,0,2002-06-03,Лысьва
3,Деревянко,182,0,2002-02-20,Оса
4,Столбова,194,0,2003-01-22,Кунгур
5,Хомич,205,0,2002-04-23,Кунгур
6,Круглов,191,1,2002-04-23,Березники
7,Иванов,192,1,2002-05-17,Кунгур
8,Петров,191,1,2002-11-25,Кунгур
9,Сидоров,196,1,2004-01-20,Кунгур
10,Капустин,196,1,2002-06-04,Кунгур
11,Томатова,201,0,2003-04-16,Кунгур
12,Ежова,214,0,2001-10-07,Лысьва
13,Микова,222,0,2001-10-07,Пермь
14,Мамин,199,1,2001-11-10,Пермь
15,Комов,195,1,2002-01-17,Пермь
```

- для простых (плоских) табличных данных

- человекочитаемый формат

- небольшой размер файла

- легко парсится

- заголовки один раз

- заголовки необязательны

- простота хранения и обработки

это просто txt файл

обычными редакторами можно редактировать

можно не использовать библиотеки

+

- данные могут быть не согласованы

ошибки в значениях полей, нарушения форматов

- избыточность

если значения часто повторяются

- проблемы с запятыми внутри полей

- не подходит для сложных структур

-

Плоские данные

CSV

```
import csv

filename = './csv/abiturs.csv'

# Чтение как обычный txt
with open(filename, 'r', encoding='utf-8') as f:
    for row in f:
        print(row.split(','))

# Чтение в список списков
with open(filename, 'r', encoding='utf-8') as f:
    reader = csv.reader(f)
    for row in reader:
        print(row)

# Чтение в список словарей
with open(filename, 'r', encoding='utf-8') as f:
    reader = csv.DictReader(f)
    for row in reader:
        print(row)
```

на примерах программ обсудить:

- формат хранения,
- способы разделения на поля,
- способы чтения и записи,
- добавления и сортировки

Плоские данные

CSV

```
import csv
```

```
data = [ ['Анна', 25, 'Москва'], ['Борис', 30, 'СПб'] ]
```

```
with open('./csv/output_0.csv', 'w', encoding='utf-8', newline='') as f:
    f.write('name,age,city\n')           # заголовок
    for row in data:                    # строки данных
        f.write(','.join(str(item) for item in row) + '\n')
```

```
with open('./csv/output_1.csv', 'w', encoding='utf-8', newline='') as f:
    writer = csv.writer(f)
    writer.writerow(['name', 'age', 'city']) # заголовок
    writer.writerows(data)
```

```
data = [
    {'name': 'Анна', 'age': 25, 'city': 'Москва'},
    {'name': 'Борис', 'age': 30, 'city': 'СПб'}
]
```

```
with open('./csv/output_2.csv', 'w', encoding='utf-8', newline='') as f:
    writer = csv.DictWriter(f, fieldnames=['name', 'age', 'city'])
    writer.writeheader()
    writer.writerows(data)
```

output.csv

```
name,age,city
Анна,25,Москва
Борис,30,СПб
```

Контрольные вопросы

Понятие «плоские данные», отличие от иерархических, когда используют
Основные способы хранения плоских данных (файлы, программы, базы)
csv-файл

- как расшифровывается
- какие бывают разделители
- способы чтения и записи
- какие сложности могут быть при чтении данных
- сравнить `csv.reader` и `csv.DictReader`
- значение атрибута `newline=''`



Вопрос 2

Иерархические данные

Hierarchical Data



- данные имеют вложенную структуру
- поле объекта может быть объектом с полями
- структура полей не обязана быть строгой
- можно делать массивы таких объектов
- есть разные форматы:
 json, xml, yaml, html

Иерархические данные json

```
{  
  "company": "Tech Corp",  
  "employees": [  
    {"name": "Анна", "role": "Developer"},  
    {"name": "Борис", "role": "Manager"}  
  ],  
  "address": {  
    "city": "Пермь",  
    "street": "Ленина"  
  }  
}
```

name, age, city
Анна, 25, Москва
Борис, 30, СПб

```
import json
```

```
with open('./json/objs.json', 'r', encoding='utf-8') as f:
    data = json.load(f)          # в словарь/список
```

из файла

```
json_string = '{"name": "Анна", "age": 25}'
data = json.loads(json_string)
print(data['name'])             # Анна
```

```
json_string = """[
    {
        "id": 12,
        "name": "Федоров"
    },
    {
        "id": 8,
        "name": "Петров"
    }
]"""
data = json.loads(json_string)
print(data[0]['name'])          # Федоров
```

из строки

```
objs.json
[
    {
        "id": 12,
        "name": "Федоров"
    },
    {
        "id": 8,
        "name": "Петров"
    }
]
```

запись

Иерархические данные

json

```
import json

data = {
    "name": "Анна",
    "age": 25,
    "hobbies": ["reading", "swimming"]
}
```

```
output.json
{
    "name": "Анна",
    "age": 25,
    "hobbies": [
        "reading",
        "swimming"
    ]
}
```

```
with open('./json/output.json', 'w', encoding='utf-8') as f:
    json.dump(data, f, indent=4, ensure_ascii=False)
```

в файл

```
json_string = json.dumps(data, indent=4, ensure_ascii=False)
print(json_string)
```

в строку

обработка,
сортировка

Иерархические данные

json

рассмотреть на примере программ

```
import yaml # pip install pyyaml
```

```
data = {
    "name": "Анна",
    "age": 25,
    "hobbies": ["reading", "swimming"]
}
```

output.yaml

```
age: 25
hobbies:
- reading
- swimming
name: Анна
```

```
with open('./data/output.yaml', 'w', encoding='utf-8') as f:
    yaml.dump(data, f, allow_unicode=True, default_flow_style=False)
```

в файл

```
with open('./data/output.yaml', 'r', encoding='utf-8') as f:
    data = yaml.safe_load(f)
```

из файла

```
print(data)
```

```
# {'age': 25, 'hobbies': ['reading', 'swimming'], 'name': 'Анна'}
```



Контрольные вопросы

Понятие «иерархические данные» - когда используют

Основные способы хранения

json-файл

- как расшифровывается
- какой формат в файле
- что можно хранить
- какая библиотека используется
- значение атрибута `indent`
- значение атрибута `ensure_ascii`



Теоретические основы информатики

Раздел 4. Хранение и обработка данных

Тема 7: Структурированные файлы
